Reducción del número de mediciones en una cámara de un píxel: patrones y reconstrucción en 2D sobre vistas de escenas 3D

Francisco Alfaro
Departamento de Electrónica
Universidad Técnica Federico Santa María
Valparaíso, Chile
francisco.alfaro@usm.cl

Ayrton Perez
Departamento de Informática
Universidad Técnica Federico Santa María
Valparaíso, Chile
ayrton.perez@usm.cl

***Resumen*—Una cámara de un píxel (Single Pixel Camera, SPC) reemplaza el sensor matricial por un detector único y una secuencia de patrones de iluminación, lo que abarata el sensor a cambio de más mediciones por imagen. Este trabajo estudia cuánta calidad se pierde al reducir esas mediciones cuando las imágenes son vistas de una escena 3D, como paso previo a su reconstrucción con 3D Gaussian Splatting. Se simula la adquisición sobre 24 vistas de cada una de cuatro escenas de Tanks and Temples y Deep Blending, con patrones Hadamard ordenados y binarios aleatorios, un modelo de detector con ruido de Poisson, ruido de lectura y cuantización de 16 bits, y se comparan la reconstrucción directa y la regularizada con variación total. Con Hadamard y variación total, la calidad media crece de 28.1 dB (PSNR) con el 5 % de las mediciones a 34.6 dB con el 50 %, y la regularización aporta entre 1.8 y 2.1 dB sobre la reconstrucción directa. Los patrones aleatorios sin regularización fallan (13.6 a 17.1 dB), pero con regularización se acercan a Hadamard a razones altas. El alcance se limita al caso 2D; la propagación del error a la escena 3D se deja como trabajo futuro. El código está disponible públicamente.**

***Index Terms*—single pixel camera, Hadamard, muestreo comprimido, variación total, 3D Gaussian splatting**

I. Introducción

Las cámaras de un píxel miden proyecciones de la escena sobre patrones codificados y reconstruyen la imagen resolviendo un problema inverso [1], [2]. Son atractivas donde fabricar un sensor matricial es costoso, por ejemplo en bandas espectrales poco habituales, pero cada imagen exige una secuencia de mediciones.

Ese costo se multiplica cuando el objetivo es una escena 3D. Métodos recientes como NeRF [3] y 3D Gaussian Splatting (3DGS) [4] necesitan cientos de vistas, de modo que cada medición ahorrada por vista reduce de forma importante el tiempo total de captura. La pregunta de este trabajo es cuántas mediciones por vista se pueden quitar antes de que la calidad caiga, y qué patrón y qué reconstrucción lo soportan mejor.

Contribuciones. (i) Una simulación SPC a resolución cercana a la nativa, con una transformada rápida de Walsh-Hadamard en GPU y un modelo explícito del detector. (ii) Una comparación de patrones (Hadamard ordenado y binario aleatorio) y de reconstrucción (directa y con variación total) sobre cuatro escenas. (iii) Estudios de ruido, de orden de patrones y de color. (iv) El código abierto de todo el flujo.

Alcance. Este artículo cubre únicamente la adquisición y reconstrucción en 2D. El entrenamiento de 3DGS con las vistas reconstruidas está implementado en el repositorio, pero sus resultados quedan fuera de este trabajo.

II. Trabajo relacionado

II-A. Cámara de un píxel y muestreo comprimido

La arquitectura de imagen comprimida con un microespejo digital (DMD) y un fotodiodo se debe a Takhar y Wakin [5], [6], y Duarte et al. [1] la formalizaron como cámara de un píxel. Se apoya en la teoría de muestreo comprimido [7], [8], que permite recuperar señales escasas con pocas mediciones. Edgar et al. [2] ofrecen una revisión del campo, y Sun et al. [9] llevaron la idea a imagen 3D con varios detectores.

II-B. Patrones: Hadamard, Fourier y su orden

Zhang et al. [10] comparan las bases de Hadamard y de Fourier. Con una base completa, el orden en que se miden los patrones decide qué información se captura primero: el orden *Russian dolls* [11] y el *cake-cutting* [12] priorizan las bajas frecuencias para lograr reconstrucciones sub-Nyquist.

II-C. Reconstrucción de escenas 3D

NeRF [3] representa la escena con un campo neuronal, y 3DGS [4] con millones de gaussianas 3D optimizadas a partir de imágenes y poses estimadas con Structure from Motion [13]. La Fig. 1 resume el renderizado. Se evalúan sobre Tanks and Temples [14] y Deep Blending [15], los mismos conjuntos que se usan aquí.

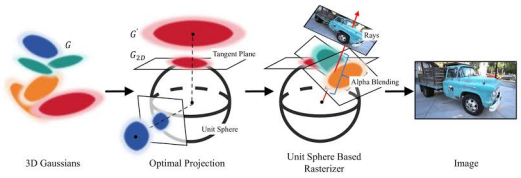


Figura 1. Renderizado de 3DGS: gaussianas 3D, proyección al plano de la imagen, mezcla alfa e imagen resultante (variante con proyección sobre la esfera unitaria). [TODO: verificar y citar la fuente de la figura]

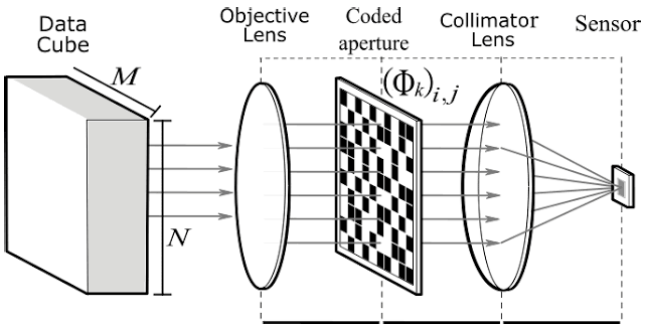


Figura 2. Arquitectura de una cámara de un píxel: la escena atraviesa una apertura codificada con el patrón Φ_k y un único sensor mide la suma. [TODO: citar la fuente de la figura (material del curso)]

III. Modelo de medición

Sea $\mathbf{x} \in \mathbb{R}^N$ una vista vectorizada, con $N = H \times W$. La SPC (Fig. 2) mide

$$\mathbf{y} = \mathbf{\Phi}\mathbf{x} + \mathbf{n}, \qquad \mathbf{\Phi} \in \mathbb{R}^{M \times N}, \tag{1}$$

con razón de medición $r = M/N$. Un DMD solo implementa máscaras $\{0, 1\}$, de modo que se miden los patrones $\mathbf{P} = (\mathbf{1} + \mathbf{H})/2$ y una medición adicional de nivel DC (todos los espejos encendidos); el coeficiente en ± 1 se recupera como $c = 2y - \text{DC}$, lo que duplica la amplitud del ruido. La alternativa diferencial (Fig. 3) mide por separado los patrones positivo y negativo y requiere el doble de mediciones.

III-A. Rejilla de medición

Hadamard exige potencias de 2, por lo que se usa una rejilla de 512×1024 ($N = 524\,288$), cercana en píxeles a las vistas de Tanks and Temples (979×546). El cambio de relación de aspecto equivale a macropíxeles no cuadrados del DMD y se deshace al guardar. La matriz $\mathbf{\Phi}$ no se almacena: se aplica con la transformada rápida de Walsh-Hadamard, y $\mathbf{H}\mathbf{H}^\top = N\mathbf{I}$ permite que $\mathbf{\Phi}\mathbf{\Phi}^\top = \mathbf{I}$ tras normalizar.

III-B. Patrones

Las filas de Hadamard se muestran en la Fig. 4. *Hadamard ordenado (cake-cutting).* Se miden primero las filas con menos bloques conexos, es decir, las frecuencias más bajas. Un patrón separable $w_i(x)w_j(y)$ tiene $(s_i + 1)(s_j + 1)$ bloques conexos, lo que da un orden analítico.

Binario aleatorio. Un Bernoulli i.i.d. denso a 512×1024 ocuparía 1.7 GB al 5 % y 17 GB al 50 % a un bit por entrada. Se usa una matriz estructuralmente aleatoria (permutación de

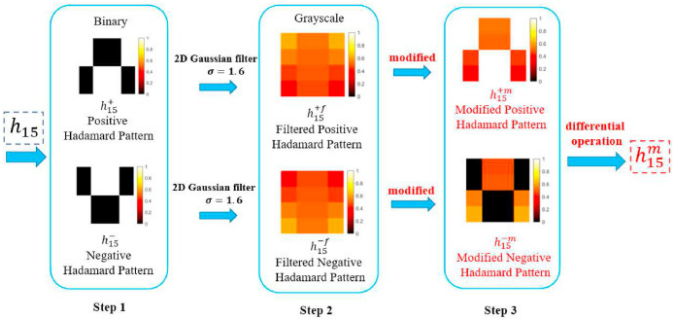


Figura 3. Un patrón de Hadamard con valores ± 1 se separa en un patrón positivo y uno negativo binarios, que un DMD puede mostrar; la figura incluye además el desenfoque de la óptica (filtro gaussiano) y la combinación diferencial. [TODO: citar la fuente de la figura]

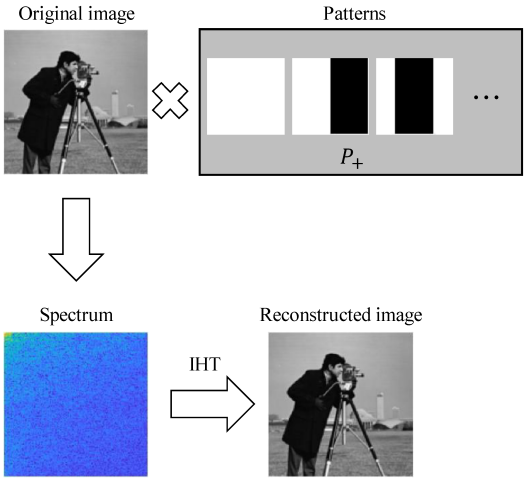


Figura 4. Patrones de la base de Hadamard ordenados por frecuencia. [TODO: citar la fuente de la figura (material del curso)]

píxeles, Hadamard y submuestreo). Con una validación a baja resolución, esta matriz y un Bernoulli denso dan PSNR casi idénticos (por ejemplo 24.39 dB y 24.31 dB al 25 %).

III-C. Detector

Cada medición incluye ruido de disparo de Poisson, ruido de lectura gaussiano y cuantización de b bits:

$$y_i = Q_b\left(\frac{\text{Pois}(\gamma\langle \mathbf{p}_i, \mathbf{x}\rangle)}{\gamma} + \mathcal{N}(0, \sigma^2)\right), \tag{2}$$

con $\gamma = 10^9$ fotones por patrón a fondo de escala, $\sigma = 10^{-5}$ y $b = 16$. La referencia DC se promedia 16 veces.

IV. Reconstrucción

IV-A. Directa

Con $\mathbf{\Phi}\mathbf{\Phi}^\top = \mathbf{I}$, la solución de mínima norma es $\hat{\mathbf{x}} = \mathbf{\Phi}^\top\mathbf{y}$, equivalente a rellenar con ceros los coeficientes no medidos.

IV-B. Regularizada con variación total

$$\hat{\mathbf{x}} = \arg\min_{\mathbf{x}} \ \tfrac{1}{2}\|\mathbf{\Phi}\mathbf{x} - \mathbf{y}\|_2^2 + \lambda\,\text{TV}(\mathbf{x}), \tag{3}$$

Tabla I
PSNR MEDIO (DB) SOBRE LAS CUATRO ESCENAS, 24 VISTAS POR ESCENA.

Patrón y método	5 %	10 %	25 %	50 %
Hadamard, directa	26.25	28.26	31.07	32.58
Hadamard, TV	**28.05**	**30.11**	**32.95**	**34.63**
Aleatorio, directa	13.62	13.93	14.94	17.10
Aleatorio, TV	26.52	28.56	31.37	33.44
Control (solo remuestreo)		41.04		

con TV isotrópica [16], resuelta con FISTA [17] y proximal de TV por FGP [18], con un máximo de 100 iteraciones y en lotes en GPU. El parámetro λ se elige entre $\{10^{-3}, 3\times 10^{-3}, 10^{-2}, 3\times 10^{-2}\}$ en cuatro vistas de entrenamiento por condición y se fija antes de medir las demás vistas, para no sesgar la evaluación.

V. DISEÑO EXPERIMENTAL

V-A. Datos y condiciones

Se usan cuatro escenas: Truck y Train (Tanks and Temples [14]) y DrJohnson y Playroom (Deep Blending [15]), con 24 vistas equiespaciadas por escena. Las razones de medición son 5, 10, 25 y 50 %, con dos patrones (Hadamard ordenado y aleatorio) y dos métodos (directa y TV). Un control de solo remuestreo a la rejilla 512×1024, sin SPC, aísla la pérdida que no proviene de la medición. La semilla es 449 en todas las corridas.

V-B. Métricas

PSNR, SSIM [19] y LPIPS-VGG [20] se calculan siempre contra la imagen original a la resolución final, con una única función para todas las condiciones.

V-C. Implementación y recursos

Las simulaciones se ejecutaron en una GPU NVIDIA GeForce RTX 4060 Laptop de 8 GB, con Python 3.11, PyTorch 2.11 y CUDA 12.8. Medir una vista toma del orden de milisegundos con la transformada rápida; la reconstrucción directa tarda entre 0.02 y 0.04 s por vista y la TV entre 0.15 y 1.3 s. Una escena completa (24 vistas, todas las condiciones y los estudios complementarios) tarda entre 12 y 15 minutos. El código se encuentra en https://github.com/fralfaro/inf449-proyecto.

VI. RESULTADOS

VI-A. Calidad frente a razón de medición

La Fig. 5 y la Tabla I resumen la calidad media sobre las cuatro escenas. Hadamard con TV es la mejor combinación en las tres métricas y a todas las razones: pasa de 28.05 dB y SSIM 0.798 con el 5 % de las mediciones a 34.63 dB y SSIM 0.914 con el 50 %. El control de solo remuestreo alcanza 41.04 dB, que es el techo del experimento, de modo que a razones altas la pérdida restante todavía depende de la medición.

VI-B. Reconstrucción directa frente a TV

Con Hadamard, la TV mejora a la reconstrucción directa en 1.80, 1.86, 1.88 y 2.05 dB a 5, 10, 25 y 50 %. En SSIM la brecha crece con la razón (0.914 frente a 0.840 al 50 %), porque la reconstrucción directa deja artefactos de bloque que la TV suaviza. Con patrones aleatorios la reconstrucción directa no sirve (13.6 a 17.1 dB), pues los coeficientes no medidos quedan distribuidos como ruido, y la TV la lleva a 26.5–33.4 dB. A razones altas el aleatorio con TV se acerca a Hadamard con TV (33.44 frente a 34.63 dB al 50 %), y la ventaja de Hadamard es mayor con pocas mediciones. La Fig. 6 muestra la misma medición reconstruida de cuatro formas.

VI-C. Comparación visual

La Fig. 7 muestra una vista de Truck con Hadamard y TV. Con el 5 % aparecen bloques en zonas de textura fina, como el follaje; desde el 25 % los bordes del camión se conservan.

VI-D. Diferencias entre escenas

La calidad depende más de la escena que del método: con Hadamard y TV al 5 % el PSNR va de 23.9 dB (Train) y 24.1 dB (Truck) a 32.6 dB (DrJohnson) y 31.5 dB (Playroom). El control de remuestreo muestra la misma separación (37.7 y 38.1 dB frente a 44.9 y 43.5 dB). Una hipótesis, no verificada aquí, es que las escenas de Deep Blending tienen mayor resolución nativa que la rejilla y por eso se submuestrean y suavizan, mientras que las de Tanks and Temples tienen un tamaño casi igual al de la rejilla. Las curvas por escena están en la Fig. 8.

VI-E. Estudios complementarios

Los estudios siguientes usan tres vistas de Truck al 25 % de mediciones, de modo que son indicativos y no estadísticamente robustos.

Ruido. Con Hadamard y TV, el PSNR baja de 29.09 dB (detector ideal) a 28.55 dB con 10^9 fotones, a 26.98 dB con 10^8 y a 19.85 dB con 10^7. El aleatorio con TV es más sensible: 28.85, 27.56, 25.12 y 17.72 dB. Medir en luz lineal en lugar de sRGB baja el resultado a 27.89 dB (Hadamard y TV).

Orden de los patrones. Al 25 % con reconstrucción directa, el orden *cake-cutting* (27.27 dB) supera a las variantes *Russian dolls* (26.83 dB) y de Fourier (26.47 dB). Al 5 % las diferencias son menores (22.40, 22.69 y 22.36 dB).

Color. Con un presupuesto total de $0{,}75N$ mediciones, la medición por canal supera a la máscara Bayer con Hadamard (27.27 frente a 25.57 dB, reconstrucción directa), pero con patrones aleatorios sin regularizar la máscara Bayer es mucho mejor (19.49 frente a 13.62 dB). Con TV, la medición por canal es mejor con Hadamard (28.56 frente a 25.12 dB) y equivalente con aleatorio (27.56 frente a 27.39 dB).

VII. DISCUSIÓN Y LIMITACIONES

- Las vistas son imágenes ya capturadas, no una captura óptica: las mediciones heredan el JPEG y el desenfoque del dataset.

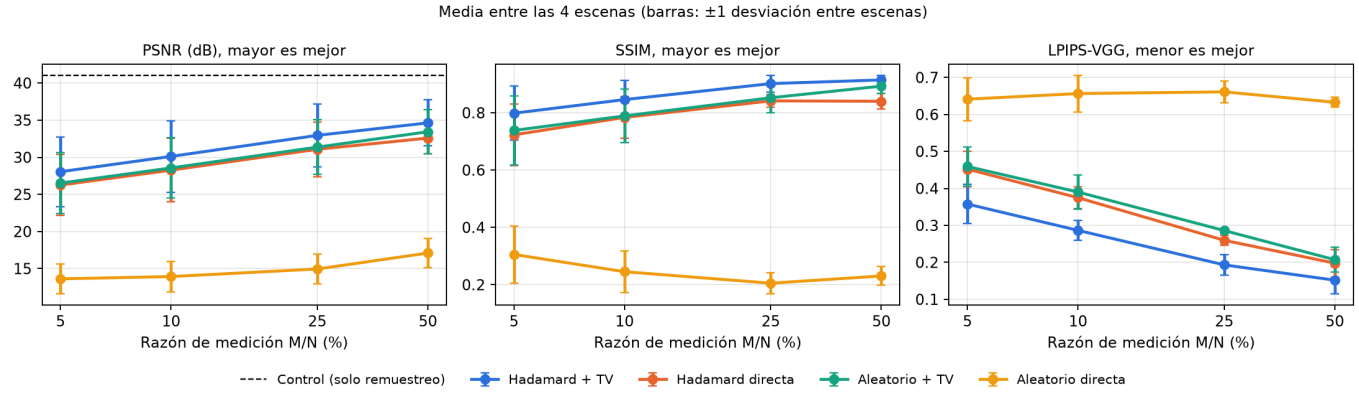


Figura 5. PSNR, SSIM y LPIPS frente a la razón de medición, medias sobre las cuatro escenas (24 vistas cada una). Las barras muestran ± 1 desviación entre escenas.



Figura 6. Una vista de Truck al 10 % de mediciones: Hadamard y aleatorio, con reconstrucción directa y con TV. Cada panel indica el PSNR de esa vista.



Figura 7. Vista 000001 de Truck: original, Hadamard con TV a 5, 10, 25 y 50 %, y control de solo remuestreo. Cada panel indica el PSNR de esa vista.

- Se mide en valores sRGB y no en radiancia lineal; el estudio de ruido sugiere que la diferencia es de 0.7 dB (Hadamard y TV) a 1.9 dB (Hadamard directa).
- La escena se asume estática durante las mediciones de cada vista.
- Se evalúan 24 vistas en cuatro escenas; las barras de la Fig. 5 reflejan sobre todo la variación entre escenas.
- Los estudios de ruido, orden y color usan tres vistas de una sola escena.
- Al pasar a 3D, las poses y la nube SfM provendrán de las imágenes originales: una SPC real no las tendría, así que los resultados 3D serán una cota optimista.

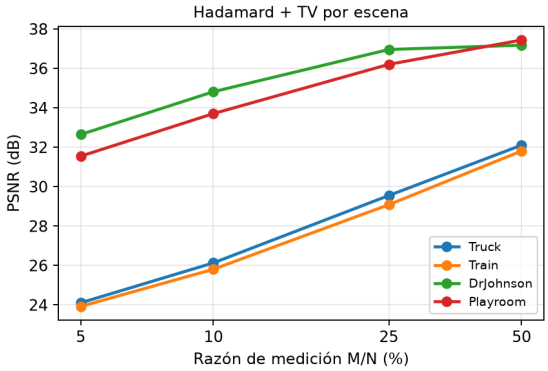


Figura 8. PSNR con Hadamard y TV, por escena.

VIII. Conclusiones y trabajo futuro

Con Hadamard ordenado y variación total se conserva una calidad media de 28.1 dB con solo el 5 % de las mediciones y de 34.6 dB con el 50 %, y la regularización aporta alrededor de 2 dB sobre la reconstrucción directa. Los patrones aleatorios requieren regularización: sin ella la imagen no es utilizable, y con ella se aproximan a Hadamard solo a razones altas. La escena influye más que el método, lo que recomienda validar con varias escenas.

Como trabajo futuro, las vistas reconstruidas alimentarán 3DGS [4] para medir cómo se propaga el error de cada vista a la escena 3D, con una validación previa del baseline frente al artículo original. También quedan por estimar las poses sin el GT, entrenar 3DGS directamente contra las mediciones y variar los patrones entre vistas. El flujo ya está implementado en el repositorio.

Uso de herramientas de IA

Durante el desarrollo se usó Claude Code de Anthropic como apoyo para explorar y revisar la implementación, organizar la explicación y preparar visualizaciones. Las fórmulas, el código, los valores tabulados y las conclusiones fueron

contrastados por los autores con la ejecución de los notebooks y con las referencias citadas.

REFERENCIAS

[1] M. F. Duarte, M. A. Davenport, D. Takhar, J. N. Laska, T. Sun, K. F. Kelly, and R. G. Baraniuk, "Single-pixel imaging via compressive sampling," *IEEE Signal Processing Magazine*, vol. 25, no. 2, pp. 83–91, 2008.

[2] M. P. Edgar, G. M. Gibson, and M. J. Padgett, "Principles and prospects for single-pixel imaging," *Nature Photonics*, vol. 13, pp. 13–20, 2019.

[3] B. Mildenhall, P. P. Srinivasan, M. Tancik, J. T. Barron, R. Ramamoorthi, and R. Ng, "NeRF: Representing scenes as neural radiance fields for view synthesis," in *European Conference on Computer Vision (ECCV)*, 2020.

[4] B. Kerbl, G. Kopanas, T. Leimkühler, and G. Drettakis, "3D Gaussian splatting for real-time radiance field rendering," *ACM Transactions on Graphics*, vol. 42, no. 4, 2023.

[5] D. Takhar, J. N. Laska, M. B. Wakin, M. F. Duarte, D. Baron, S. Sarvotham, K. F. Kelly, and R. G. Baraniuk, "A new compressive imaging camera architecture using optical-domain compression," in *Computational Imaging IV, Proc. SPIE*, vol. 6065, 2006.

[6] M. B. Wakin, J. N. Laska, M. F. Duarte, D. Baron, S. Sarvotham, D. Takhar, K. F. Kelly, and R. G. Baraniuk, "An architecture for compressive imaging," in *IEEE International Conference on Image Processing (ICIP)*, 2006.

[7] D. L. Donoho, "Compressed sensing," *IEEE Transactions on Information Theory*, vol. 52, no. 4, pp. 1289–1306, 2006.

[8] E. J. Candès, J. Romberg, and T. Tao, "Robust uncertainty principles: Exact signal reconstruction from highly incomplete frequency information," *IEEE Transactions on Information Theory*, vol. 52, no. 2, pp. 489–509, 2006.

[9] B. Sun, M. P. Edgar, R. Bowman, L. E. Vittert, S. Welsh, A. Bowman, and M. J. Padgett, "3D computational imaging with single-pixel detectors," *Science*, vol. 340, no. 6134, pp. 844–847, 2013.

[10] Z. Zhang, X. Wang, G. Zheng, and J. Zhong, "Hadamard single-pixel imaging versus Fourier single-pixel imaging," *Optics Express*, vol. 25, no. 16, pp. 19 619–19 639, 2017.

[11] M.-J. Sun, L.-T. Meng, M. P. Edgar, M. J. Padgett, and N. Radwell, "A Russian Dolls ordering of the Hadamard basis for compressive single-pixel imaging," *Scientific Reports*, vol. 7, p. 3464, 2017.

[12] W.-K. Yu, "Super sub-Nyquist single-pixel imaging by means of cake-cutting Hadamard basis sort," *Sensors*, vol. 19, no. 19, p. 4122, 2019.

[13] J. L. Schönberger and J.-M. Frahm, "Structure-from-motion revisited," in *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016.

[14] A. Knapitsch, J. Park, Q.-Y. Zhou, and V. Koltun, "Tanks and Temples: Benchmarking large-scale scene reconstruction," *ACM Transactions on Graphics*, vol. 36, no. 4, 2017.

[15] P. Hedman, J. Philip, T. Price, J.-M. Frahm, G. Drettakis, and G. Brostow, "Deep blending for free-viewpoint image-based rendering," *ACM Transactions on Graphics*, vol. 37, no. 6, 2018.

[16] L. I. Rudin, S. Osher, and E. Fatemi, "Nonlinear total variation based noise removal algorithms," *Physica D: Nonlinear Phenomena*, vol. 60, no. 1–4, pp. 259–268, 1992.

[17] A. Beck and M. Teboulle, "A fast iterative shrinkage-thresholding algorithm for linear inverse problems," *SIAM Journal on Imaging Sciences*, vol. 2, no. 1, pp. 183–202, 2009.

[18] ——, "Fast gradient-based algorithms for constrained total variation image denoising and deblurring problems," *IEEE Transactions on Image Processing*, vol. 18, no. 11, pp. 2419–2434, 2009.

[19] Z. Wang, A. C. Bovik, H. R. Sheikh, and E. P. Simoncelli, "Image quality assessment: From error visibility to structural similarity," *IEEE Transactions on Image Processing*, vol. 13, no. 4, pp. 600–612, 2004.

[20] R. Zhang, P. Isola, A. A. Efros, E. Shechtman, and O. Wang, "The unreasonable effectiveness of deep features as a perceptual metric," in *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2018.